一份缓存，四个视角：ZZZ 剧情进度 × KV 块可见性

同一份世界观只 prefill 一次；人物只声明"我看不到哪些块"，引擎在注意力层把块剔除。 两组对照共用**完全相同的 token 序列**，唯一变量是可见性位图。

21 页 / 3,405 tok
共享语料（213 个 16-token 块）

7/8 → 0/8
越界：不遮 → 遮蔽

4/4 = 4/4
该答的题：不遮 = 遮蔽

58 vs 58 ms
TTFT：不遮 vs 遮蔽

角色与知识边界

Banyue
剧情进度 **2.4**
不可读 16 页 / 76% 块
Aria、Cissia、Claret Flint、Nangong Yu...

Aria
剧情进度 **2.6**
不可读 12 页 / 56% 块
Cissia、Claret Flint、Nangong Yu、Norma Hollowell...

Promeia
剧情进度 **2.8**
不可读 8 页 / 38% 块
Claret Flint、Norma Hollowell、Phoenix Reffaella、Pyrois...

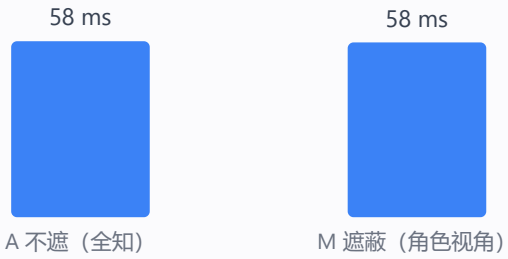
Claret Flint
剧情进度 **3.2**
不可读 1 页 / 5% 块
Phoenix Reffaella

逐题对照

人物	提问	正解	A 不遮	M 遮蔽	答案	TTFT A/M (ms)	TTOT A/M (ms)
Banyue 进度 2.4	When is Banyue's birthday?	July 24th	July 24th 复现正解	July 24th 复现正解	同	55 / 59	176 / 164
	When is Roxy Ifrita Pryce's birthday?	December 29th	December 29th 复现正解	July 24th 未复现	异	66 / 51	178 / 163
	When is Aria's birthday?	June 7th	June 7th 复现正解	Aria's birthday is July 24th. 未复现	异	58 / 63	158 / 308

	When is Sigrid de L'Azur's birthday?	April 23rd	July 23rd 未复现	July 24th 未复现	异	58 / 64	166 / 172
Aria 进度 2.6	When is Aria's birthday?	June 7th	June 7th 复现正解	June 7th 复现正解	同	50 / 60	135 / 138
	When is Claret Flint's birthday?	July 23rd	July 23rd 复现正解	July 24th 未复现	异	50 / 60	166 / 164
	When is Sigrid de L'Azur's birthday?	April 23rd	April 23rd 复现正解	I don't know. 未复现	异	61 / 62	181 / 171
Promeia 进度 2.8	When is Promeia's birthday?	December 23rd	December 23rd 复现正解	December 23rd 复现正解	同	66 / 69	198 / 188
	When is Claret Flint's birthday?	July 23rd	Claret Flint's birthday is July 23rd. 复现正解	Claret Flint's birthday is July 24th. 未复现	异	59 / 58	331 / 329
	When is Roxy Ifrita Pryce's birthday?	December 29th	December 29th 复现正解	I don't know. 未复现	异	56 / 53	164 / 170
Claret Flint 进度 3.2	When is Claret Flint's birthday?	July 23rd	July 23rd 复现正解	July 23rd 复现正解	同	57 / 53	182 / 180
	When is Phoenix Reffaella's birthday?	October 31st	Phoenix Reffaella's birthday is October 31st. 复现正解	Phoenix Reffaella's birthday is March 17th. 未复现	异	75 / 54	382 / 369

延迟：遮蔽几乎零成本



同一段 token 序列，只换可见性位图：**TTFT 中位数 58 ms vs 58 ms**， **TTOT 中位数 176 ms vs 174 ms**，差异在噪声内（每格 3 次取中位数）。
为什么几乎免费：序列没变，前缀缓存照常命中；被遮块在 kernel 之前就从 KV 索引里剔除，连读都不读。

现场片段（Banyue，剧情进度 2.4）

【Banyue 的提问】When is Banyue's birthday? （该答；正解 July 24th）

不遮 July 24th

遮蔽 July 24th

【Banyue 的提问】When is Roxy Ifrita Pryce's birthday? （不该答；正解 December 29th）

不遮 December 29th

遮蔽 July 24th

看什么、别误读什么

看两点： ① 不该答的 8 题里，不遮臂复现正解 **7 次**，遮蔽臂 **0 次**； ② 该答的 4 题里，两臂答案**逐字一致 4/4**，且都复现正解 4/4。
别误读： ①「越界」的定义是"复现了受限版本的正解"，不是逐条人工审核； ② 1.7B 在 21 页里定位本就弱，个别行（Sigrid）不遮臂也没复现，该行不作越界证据； ③ n 小（4 人 × 2–4 题 × 3 次），只演示机制，不是基准。

复现

```
NPC_VIS_BLOCKS=/path/blocks.json python -m vllm.entrypoints.openai.api_server --model Qwen3-1.7B
<br>
  --attention-backend FLEX_ATTENTION --enable-prefix-caching --enforce-eager --port 8001
python demo_persona.py --pages 21 --reps 3   # → demo_persona.json
python demo_report.py demo_persona.json demo_report.html
```

数据：demo_persona.json | 每格 3 次重复，答案一致率 100%（表内取众数） | TTFT = 首 token 时间，TTOT = 末 token 时间（端到端） | 生成于 2026-10-28