绝区零资料库：一份背景，按角色挡住不该看的页

工作概论

本工作提出：**通过结构性先验对缓存块进行屏蔽，把可见性约束直接注入注意力分布。** 于是同一个人物扮演系统在不同视角下，可以把**该人物本身不该获取的信息**挡在注意力之外—— 不是靠提示词说"别提"，而是让模型在计算这一步就读不到。

由此保证人物扮演的正确性：**该知道的答得对，不该知道的说不出来。**

下面用六页真实角色资料演示这套机制。

我们做了什么

六页真实角色资料（安比·德玛拉、艾莲·乔、妮可·德玛拉、冯·莱卡恩、星见雅、克拉蕾特·弗林特）+ 一段系统提示。资料只准备一次，之后每个角色只决定自己能看哪几页。

1. **资料只建一次。**六页角色资料放进同一份背景里，整体只算一次，不重复加载。
2. **每一页是单独建的。**建第 2 页时，第 1 页被挡掉；建第 3 页时，前两页被挡掉……所以每一页只看到系统提示，看不到别的角色页，也不依赖谁先谁后。
3. **提问时按人物挡。**妮可只熟悉早期角色，星见雅和克拉蕾特那两页对她挡住；其余照常。

```
系统提示
├─ 建【安比】    ：只看得到系统提示
├─ 建【艾莲】    ：前面 1 页已挡
├─ 建【妮可】    ：前面 2 页已挡
├─ 建【莱卡恩】  ：前面 3 页已挡
├─ 建【星见雅】  ：前面 4 页已挡
└─ 建【克拉蕾特】：前面 5 页已挡
```

怎么确认"每页是独立加载的"

按上面的方式，正面顺序建一次资料库；再按完全相反的顺序重建一次，然后问同样的六个问题。 两次结果：**五页逐字相同，一页只是措辞不同（"是Thiren种族" / "的种族是Thiren"），意思一样。** 顺序换过来答案不变，说明每一页只跟它自己有关——建它的时候确实看不到前面的页。

四个输入输出对照

问的是同一句话，唯一区别是「挡」还是「不挡」。

安比·德玛拉的生日是哪天？ （早期角色，本来就该知道）

不挡	安比·德玛拉的生日是2月20日。
挡	安比·德玛拉的生日是2月20日。

两边一模一样。**该知道的照样答对。**

艾莲·乔是什么种族？ （早期角色，本来就该知道）

不挡	艾莲·乔是Thiren（鲨鱼）种族。
挡	艾莲·乔是Thiren（鲨鱼）种族。

逐字相同。**没有受影响。**

星见雅有多高？ （星见雅那页对妮可挡掉了）

不挡	星见雅的身高是170 cm (5'7", ears included)。 ← **说出来了**
挡	星见雅的身高没有在提供的资料中提及。 ← **没说出来**

正解 170 cm。不挡时直接说出来；挡掉后它明确说资料里没有。

克拉蕾特·弗林特的生日是哪天？ （克拉蕾特那页对妮可挡掉了）

不挡	克拉蕾特·弗林特的生日是7月23日。 ← **说出来了**
挡	克拉蕾特·弗林特的生日是1月4日。 ← **没说出来**

正解 7月23日。挡掉后它给了别人的生日（1月4日）。

该知道的 2 个问题：挡不挡，答案一模一样。

不该知道的 2 个问题：不挡，2 个全说出来了；挡掉，0 个说出来。

以上为程序实际输出的原话，逐字照录。